

**\*\*ShahnamehMap — و مانیتورینگ MLOps سند ۴,۱۱: برنامه \*\*** #

نسخه: \*\*۱,۰\*\*

تاریخ: \*\*۱۵/۰۹/۱۴۰۳\*\*

ML مهندس / (CTO) تهیه کننده: \*\*مدیر فنی\*\*

وضعیت: \*\*فعال\*\*

---

**\*\*یکپارچه سازی ایمن و مقیاس پذیر MLOps: فلسفه ۱. \*\*** ##

اتوماسیون، کنترل و نظارت بر \*\*، ShahnamehMap در MLOps هدف  
چرخه حیات مدل های یادگیری ماشین\*\* است تا اطمینان حاصل شود که  
مدل ها \*\*به طور مداوم، قابل اعتماد و با کیفیت\*\* در سرویس  
نسخه بندی، ) عمل می کنند. ما از \*\*اصول مهندسی نرم افزار Production  
استفاده می کنیم ML برای سیستم های \*\* (CI/CD تست،

---

**\*\* و مراحل کلیدی (ML Lifecycle) چرخه حیات مدل ۲. \*\***

mermaid

graph LR

A[آزمایش & توسعه] --> B[نیاز کسب و کار / مشکل];

B --> C[انتشار & استقرار];

C --> D[سرویس دهی & مانیتورینگ];

D --> E[بازآموزی & اعتبارسنجی];

E --> C;

D --> F[بازنشانی & آرشیو];

...

**\*\* (MLOps Stack) زیرساخت و ابزارها ۳. \*\***

**\*\* لایه \*\* | ابزار (انتخاب فعلی) \*\* | هدف \*\* | دلیل انتخاب \*\***

|

| :--- | :--- | :--- | :--- |

داده/مدل) | ردیابی نسخه‌های مختلف داده، کد و ( \*\*Version Control\*\* | \*\*DVC (Data Version Control)\*\* (کد) | \*\*GitLab\*\* | \*\*ورژن کنترل کد & داده\*\* | سبک و مناسب داده‌های کوچک - DVC. موجود CI/CD مدل. | یکپارچه با متوسط |

با متادیتا. | \*\*S3/MinIO\*\* پوشه ساختار یافته در \*\*Storage\*\* + \*\*DVC Remote (Model Registry)\*\* ذخیره‌سازی مدل‌ها | ذخیره، وابسته‌سازی و بازیابی مدل‌های آموزش دیده. | سادگی. در صورت نیاز ارتقا \*\*MLflow\*\* به قابلیت‌های پیشرفته (مانند مدل‌های مرحله‌بندی) به خواهیم داد |

کانتینر \*\*GitLab CI/CD\*\* + \*\*CI/CD خط لوله\*\* | خودکارسازی آموزش، تست و استقرار مدل. | یکپارچگی با \*\*Docker\*\* | موجود DevOps زیرساخت |

در \*\*Docker\*\* کانتینر | \*\*Runtime\*\* محیط اجرا | ایزوله کردن و مقیاس سرویس مدل. | | \*\*Kubernetes (K8s)\*\* | استفاده از زیرساخت موجود |

در کانتینر. | \*\*FastAPI (API REST)\*\* | \*\*Serving\*\* استقرار | ارائه پیش‌بینی‌های مدل به سرویس‌های دیگر. | سادگی، سازگاری با معماری میکروسرویس |

، (متریک) **Prometheus** | مانیتورینگ & لاگینگ |  
لاگ، **Loki** (تشخیص)، **Grafana** (داشبورد)،  
سفارشی). | نظارت بر عملکرد، سلامت و کیفیت مدل. | استفاده از **Drift**  
| .موجود **Observability** استک

برای آزمایش) + **JupyterHub** | **اورکسترسیون/آزمایش** |  
(Batch/برای اجرای دسته‌ای) **استاندارد Python** **اسکرپت‌های**  
| .کنترل و انعطاف | **Batch**. محیط توسعه و اجرای

---

**RACI Matrix**) نقش‌ها و مسئولیت‌ها. **۴** ##

<b>DevOps</b>	<b>مهندس</b>	<b>ML</b>	<b>فعالیت</b>	<b>مهندس</b>
<b>مدیر محصول</b>	<b>مهندس داده</b>			
----	----	----	----	----
(مشاوره زیرساخت) C	(انجام) R	آزمایش و توسعه مدل		
(مشاوره داده) C	(تصویب نیاز) A			

**\*\*R\*\*** | (تعریف مراحل) R | **\*\*مدل CI/CD ایجاد خط لوله\*\*** |  
| | | | (پیاده‌سازی)

**\*\*R\*\*** | C | **\*\*R\*\*** | | | **\*\*آموزش و اعتبارسنجی مدل\*\*** |  
| (داده)

**\*\*R\*\*** | (تأیید کیفیت) A | **\*\*انتشار و استقرار مدل\*\*** |  
| | | | (استقرار)

| (تحلیل، تنظیم آستانه) **\*\*R\*\*** | **\*\*مانیتورینگ و هشدار مدل\*\*** |  
| C | | | **\*\*R\*\*** (تنظیم ابزار)

A | C | **\*\*R\*\*** | (پیشنهاد) **\*\*Rollback/تصمیم بازآموزی\*\*** |  
| | | (تصویب کسب‌وکار)

---

**\*\* (ML Pipeline) برای مدل CI/CD خط لوله ۵. \*\* ##**

یا `main` یا اسکریپت‌های آموزش در شاخه (`/ml/`) هر بار که کد مدل  
آپدیت می‌شود، خط لوله زیر به طور خودکار اجرا می‌شود `develop`

```
``yaml
```

```
# .gitlab-ci.yml (بخش ML)
```

```
stages:
```

```
- test-ml
```

```
- train-model
```

```
- evaluate-model
```

```
- build-model-image
```

```
- deploy-to-staging
```

```
train-and-evaluate:
```

```
stage: train-model
```

```
script:
```

```
- python train.py --config configs/model_v1.yaml #
```

```
DVC آموزش با
```

```
- dvc metrics show # نمایش معیارهای ارزیابی
```

```
- python tests/model_tests.py # اجرای تست‌های واحد مدل
```

```
artifacts:
```

```
paths:
```

- model.pkl # خروجی آموزش

- metrics.json

only:

- main

- develop

- /^release-.\*\$ /

deploy-model-staging:

stage: deploy-to-staging

script:

- docker build -t shahnameh-rec-model:\$CI\_COMMIT\_SHA .

- kubectl set image deployment/ml-recommender model=shahnameh-rec-model:\$CI\_COMMIT\_SHA -n staging

only:

- develop # اتوماتیک به استیجینگ

...

## **\*\* (Quality Gates) دروازه‌های کیفیت \*\***

۱. **\*\*Gate 1 (Unit Tests) تست کد:\*\*** عبور از تست‌های واحد
۲. **\*\*Gate 2 (تست داده):\*\*** بررسی کیفیت داده ورودی آموزش (شدید، توزیع منطبق Missingness وجود).
۳. **\*\*Gate 3 (معیارهای ارزیابی):\*\*** مدل جدید باید از لحاظ **\*\*Precision@5\*\*** و **\*\*Recall@10\*\*** **\*\*۹۵٪\*\*** حداقل به اندازه **\*\*۹۵٪\*\*** عملکرد داشته باشد. در غیر این صورت، خط لوله (Production) مدل قبلی متوقف و هشدار داده می‌شود.
۴. **\*\*Gate 4 (A/B Test در Staging):\*\*** مدل Production قبل از **\*\*۱۰٪\*\*** از ترافیک واقعی **\*\*به مدت حداقل Staging جدید در محیط تست می‌شود. تنها در صورت بهبود یا عدم تغییر معنی‌دار A/B ۴۸ ساعت\*\*** راه می‌یابد Production ، به (CTR مانند) معیارهای کسب‌وکار.

---

## **\*\* Production مانیتورینگ جامع در ۶. \*\* ##**

مانیتور می‌کنیم Production ما چهار نوع مشکل اصلی را در مدل



### مانیتورینگ عملکرد سخت‌افزاری/زیرساختی ۶,۱.\*\*\* (Infrastructure Monitoring)\*\*

- \* مصرفی کانتینر مدل، زمان CPU/Memory \*\*:متریک‌ها\*\* \*
- . HTTP (Δxx)، نرخ خطای API (Latency) پاسخگویی
- . K8s های Exporter از طریق) Prometheus\*\* \*\*:ابزار\*\* \*
- \* یا نرخ خطا < ۱٪ برای ۵ Latency P95 > 300ms هشدار: \*\* اگر \*\* \*
- دقیقه.

### مانیتورینگ دقت مدل ۶,۲.\*\*\* (Model Performance Monitoring)\*\*

- \* چالش: \*\* در سیستم‌های توصیه‌گر، \*\*برچسب حقیقت زمینی\*\* \*
- بلافاصله در دسترس نیست\*\* (کاربر ممکن است هفته (Ground Truth) بعد با یک توصیه تعامل کند).
- \* \*\*:راهکار (Proxy Metrics)\*\* \*
- \* Real-time بر روی توصیه‌ها: \*\*ردیابی (CTR) نرخ کلیک\*\* \*
- \* نرخ شروع بازی پس از \*\*:Conversion Rate) نرخ تبدیل\*\* \*
- کلیک روی توصیه

\* \*\* میانگین زمان صرف شده در بخش (Engagement):\*\* مشارکت \*  
توصیه‌ها

\* \*\* روزانه نسبت به میانگین متحرک ۷ روزه \*\* بیش CTR هشدار: \*\* اگر \*  
از ۲۵٪ افت \*\* کند

\*\*\* \*\* (Data Drift Monitoring) مانیتورینگ انحراف داده ۶,۳. \*\*

می‌تواند عملکرد \*\* (Feature Drift) انحراف در توزیع \*\* ورودی‌های مدل  
را خراب کند

\* \*\* `user\_avg\_rating`, ویژگی‌های تحت نظارت \*  
`campaign\_difficulty\_tag`, `interaction\_type\_weight`.

روش: \*\* مقایسه توزیع \*\* ویژگی‌های هر درخواست ورودی \*  
با توزیع \*\* داده‌های آموزشی \*\* (مرجع) با استفاده از \*\* Production  
PSI (Population Stability یا KL Divergence \*\* آماره‌های  
به صورت روزانه \*\* Index)

\* \*\* برای هر ویژگی کلیدی \*\*  $0.2 < \text{PSI}$  هشدار: \*\* اگر \*  
(نشان‌دهنده تغییر معنی‌دار)

## ### \*\*۶,۴. مفهوم انحراف مانیتورینگ (Concept Drift Monitoring)\*\*

انحراف در رابطه بین ورودی و خروجی. برای ما، یعنی آیا کاربران هنوز به ویژگی‌های قدیمی (مثلاً "نژاد پهلوان") همانند گذشته واکنش نشان می‌دهند؟

روش: ذخیره یک نمونه تصادفی ۱٪ از درخواست‌های پیش‌بینی به همراه نتیجه تعامل کاربر (مثلاً کلیک/عدم کلیک) در روی **Logistic Regression** (مثلاً) آینده. هر هفته، یک مدل ساده مدلی که روی داده AUC آن را با AUC این داده جدید آموزش می‌دهیم و قدیمی آموزش دیده مقایسه می‌کنیم.

باشد  **$AUC > 0.5$**  هشدار: اگر افت

---

**\*\*و مدیریت نسخه (Retraining Policy) سیاست بازآموزی. \*\*##**

**\*\* (Scheduled Retraining): بازآموزی برنامه‌ریزی شده. \*\*##**

فرکانس:\*\*\* هفتگی\*\* برای مدل توصیه گر (با داده فعلی). این \*\* \*

فرکانس با رشد داده می تواند تغییر کند

GitLab CI در (Cron Job) زمان بند \*\*:\*(Trigger) ماشه \*\* \*

به طور خودکار ('train-model' مرحله) CI/CD روند:\*\*\* خط لوله \*\* \*

معیارهای ارزیابی)\*\*\* عبور کرد، ( Gate 3 \*\* اجرا می شود. اگر مدل جدید از

A/B \*\* مستقر شده و وارد مرحله \*\*Staging\*\* به طور خودکار در

می شود \*\*Test

(Event-Triggered) بازآموزی مبتنی بر رویداد ۷,۲۰ \*\* ####

Retraining):\*\*

\*\*\*ماشه ها \*

یا افت  $PSI > 0.3$  \*\* :شدید Data/Concept Drift هشدار \*\* ۱.

$AUC > 0.1$ ).

۲. \*\* Proxy Metrics: \*\* (افت  $CTR < 40\%$  شدید \*\*

تغییر اساسی در محصول:\*\*\* راه اندازی یک ویژگی بزرگ که \*\* ۳.

الگوهای رفتار کاربر را تغییر می دهد

را مطلع می کند. آنها به صورت دستی خط ML روند:\*\*\* هشدار، تیم \*\* \*

لوله بازآموزی را راه اندازی و فرآیند را تسریع می کنند

\*\*\* \*\*۷,۳. مدیریت نسخه‌ها (Versioning):\*\*

\* \*\* قالب: \*\* `MODEL\_NAME-vMAJOR.MINOR.PATCH`

\* \*\*MAJOR:\*\* (باعث می‌شود تغییر معماری یا شکست در سازگاری (سرویس‌های مصرف‌کننده نیاز به به‌روزرسانی داشته باشند)

\* \*\*MINOR:\*\* اضافه شدن ویژگی‌ها یا بهبود عملکرد (سازگار (عقب‌رو).

\* \*\*PATCH:\*\* رفع باگ یا بازآموزی با داده جدید (سازگار عقب‌رو).

\* \*\* ذخیره‌سازی: \*\* هر نسخه از مدل، همراه با \*\*کد، داده و در رجیستری مدل (DVC از طریق) هایپراپارامترهای \*\* دقیقاً تکرارپذیر ذخیره می‌شود.

---

## \*\* (Rollback & Recovery) و بازیابی Rollback استراتژی ۸. \*\*

\*\* اصل: \*\* توانایی بازگشت سریع به آخرین نسخه سالم مدل در کمتر از \*\*۱۰ دقیقه.

های Deployment\*\* به عنوان Production روش: \*\*مدل های\*\* \*  
آن ساده است rollback مدیریت می شوند. مکانیزم K8s\*\*

```
```bash
```

```
kubectl rollout undo deployment/ml-recommender
```

```
```
```

\*\* (stable) را به \*\*نسخه قبلی Deployment این دستور،  
برمی گرداند.

\*\*دستی Rollback ماشه های\*\* \*

۱. هشدارهای بحرانی مانیتورینگ که نشان دهنده خرابی کامل مدل است.

۲. استیجینگ A/B Test شناسایی باگ های جدی در

۳. درخواست مدیر محصول به دلیل رفتار غیرمنتظره مدل

یا خرابی سرویس مدل)، ( Rollback در طول \*\*Fallback State:\*\* \*  
(مثلاً) \*\* (Heuristic Fallback) سیستم به \*\*الگوریتم هیورستیک ساده  
توصیه محبوب ترین ها + جدیدترین ها) تغییر حالت می دهد تا تجربه کاربر  
کاملاً قطع نشود.

---

**\*\*جمع‌بندی: قابل اعتماد و قابل نگهداری؟ ۹. \*\*##**

ما در مسیر قابل اعتماد و قابل ML با استناد به این برنامه، \*\*سیستم  
نگهداری بودن قرار دارد\*\*، زیرا

ریسک/اقدام \*\* | ShahnamehMap معیار بلوغ\*\* | \*\*وضعیت\*\* |  
\*\*آینده |

| :--- | :--- | :--- |

عالی: \*\* کد، داده و \*\* ✓ | \*\* (Reproducibility) تکرارپذیری\*\* |  
| - | .ورژن می‌شوند DVC مدل با

برای CI/CD \*\*:خوب\*\* ✓ | \*\* (Automation) اتوماسیون\*\* |  
و Drift آموزش و استقرار پایه وجود دارد. | نیاز به اتوماسیون کامل تشخیص  
| .بازآموزی

در حال توسعه: \*\* ⚠ | \*\* (Monitoring) مانیتورینگ\*\* |  
Drift برقرار است. مانیتورینگ Proxy Metrics مانیتورینگ زیرساخت و  
| .و یکپارچه‌سازی هشدارها Drift در حال پیاده‌سازی. | تکمیل مانیتورینگ

خوب: \*\* تست واحد و \*\* ✓ | \*\* (Testing) تست و اعتبارسنجی \*\* |  
وجود دارد. | افزودن تست‌های یکپارچگی CI دروازه کیفیت مبتنی بر معیار در  
خودکار A/B Test و (Integration) |

Rollback خوب: \*\* استراتژی \*\* ✓ | \*\* Rollback مدیریت خطا و \*\* |  
تعریف شده است. | مستندسازی دقیق‌تر سناریوهای Fallback ساده و  
Rollback. |

اگر تغییرات \*\* Drift. \*\* بزرگ‌ترین ریسک فعلی: تشخیص به موقع \*\*  
را دیر تشخیص دهیم، مدل به (Concept Drift) تدریجی در رفتار کاربران  
قوی (بخش Drift تدریج بی‌اثر می‌شود. \*\* پیاده‌سازی سیستم مانیتورینگ  
\*\* ۶,۳ و ۶,۴) اولویت فوری ماست

نتیجه: \*\* ما از \*\* بمب ساعتی \*\* (مدل بدون نظارت) فاصله گرفته‌ایم و \*\*  
یک \*\* چرخه حیات کنترل‌شده و مبتنی بر داده \*\* برای مدل‌های خود ایجاد  
کرده‌ایم. این چارچوب به ما امکان می‌دهد با اطمینان، مدل‌های بیشتری را در  
آینده توسعه و مستقر کنیم