

**\*\*ShahnamehMap — سند ۴,۸: برنامه عملکرد و مقیاس پذیری\*\*** #

نسخه: \*\*۱,۰\*\*

تاریخ: \*\*۰۱/۰۹/۱۴۰۳\*\*

(CTO) تهیه کننده: \*\*مدیر فنی\*\*

وضعیت: \*\*فعال\*\*

---

**\*\*۱. اهداف سطح سرویس (Service Level Objectives - SLOs)\*\*** ##

و **\*\* (Reliability) های ما تعهد داخلی برای قابلیت اطمینان SLO**  
ها مبنای SLO سیستم است. این **\*\* (Performance) کارایی**  
تصمیم گیری های مهندسی و تجاری هستند.

هدف \*\* | **\*\* (SLI) سرویس/کندکتور\*\*** | **\*\* شاخص سطح سرویس\*\*** |  
| **\*\* توضیح\*\*** | **\*\* (SLO) سطح سرویس** |  
| :--- | :--- | :--- | :--- |

درخواست‌های موفق | **\*\*API Gateway (REST همه سرویس‌های)\*\*** |  
نسبت به کل درخواست‌ها. | **\*\*۹۹,۵٪\*\*** در هر دوره (HTTP 2xx/3xx)  
|. (در ماه Downtime ساعت ۳,۵ ~) ۲۸ روزه. | ۰,۵٪ خطای مجاز

اتصالات | **\*\*Game Engine (Real-time اتصالات) سرویس\*\*** |  
پایدار (بدون قطعی غیرعمدی) نسبت به کل اتصالات. | WebSocket  
Real-time **\*\*۹۹٪\*\*** در هر دوره ۲۸ روزه. | تحمل ۱٪ قطعی برای  
|. (سخت‌گیرانه)

برای (P95) های اصلی **\*\*** | زمان پاسخ API (Latency) تأخیر **\*\*** |  
• `POST /api/characters` • `GET /api/campaigns` |  
یعنی P95. | P95 برای **\*\*۲۰۰ms زیر\*\*** |  
|. ۹۵٪ درخواست‌ها در این زمان پاسخ می‌گیرند

زمان بین | **\*\*Game Action Latency (تأخیر عملیات بازی)\*\*** |  
توسط همه State توسط کاربر و دریافت به روزرسانی Action ارسال یک  
برای تجربه بازی | P99 برای **\*\*۵۰۰ms زیر\*\*** | (P99) بازیکنان اتاق  
|. روان حیاتی است

درصد زمان قابل | **\*\*Overall Uptime (در دسترس بودن کلی)\*\*** |  
دسترسی بودن سرویس از دید کاربر نهایی. | **\*\*۹۹٪\*\*** در هر دوره ۳ ماهه.  
|. | معیار سطح بالای سلامت کسب و کار

، بودجه خطای ما در 99.5% SLO با \*\* (Error Budget): بودجه خطا \*\*  
ماه ۰.۵% (۴۳,۲ دقیقه) است. اگر در هفته اول ماه ۰.۴% خطا مصرف کنیم،  
\*\*تیم موظف است توسعه فیچرهای جدید را متوقف کند\*\* و تمام تمرکز را  
بر بهبود پایداری بگذارد.

---

\*\* (Capacity Planning) برنامه اندازه گیری و ظرفیت سنجی. \*\* ##

### \*\*۲,۱. معیارهای کلیدی عملکرد (Key Performance Metrics)\*\*

:مانیتور می کنیم \*\*Real-time\*\* ما این متریک ها را به صورت

متریک \*\* | هدف \*\* | ابزار مانیتورینگ \*\* | هشدار \*\* |  
(Alert) \*\* |

| :--- | :--- | :--- | :--- |

| - | API Gateway به \*\* (RPS) نرخ درخواست \*\* |

| افزایش ناگهانی < ۵۰% | \*\*Grafana\*\* + \*\*Prometheus\*\* |

میانگین > | **CPU Utilization** (Game Engine سرویس) |  
برای ۸۰٪ > | Node Exporter + K8s Metrics | ۶۰٪، پیک > ۸۵٪  
| بیش از ۵ دقیقه

| **Memory Utilization** (Game Engine سرویس) | < ۷۰٪ |  
Node Exporter + K8s Metrics | > ۸۵٪.

| **Redis INFO** - | **فعال WebSocket اتصالات** |  
نزدیک شدن به حد نظری هر نمونه | Prometheus + **command**  
| (~۷۰۰).

از ۸۰٪ < | **PostgreSQL Connections** |  
`max\_connections` | **pg\_stat\_activity** + Prometheus  
| > ۹۰٪.

| **Redis Latency** (P99) | < ۵ms | **Redis**  
**Monitoring** | > ۱۰ms.

و نقاط گلوگاه شناخته (Capacity Model) مدل ظرفیت ۲,۲ **###**  
**شده**

و **کاربر فعال ماهانه** (CCU) **ما بر اساس** **کاربر فعال همزمان**  
**برنامه ریزی می کنیم** (MAU)

**\*\*فرضیات مدل\*\***

\* **\*\*WebSocket\*\*** اتصال ۱ **\*\*≈ (CCU)\*\*** هر **\*\*کاربر فعال همزمان\*\*** در دقیقه REST درخواست ۵~

\* **\*\*CCU ≈ (یعنی ۱۰,۰۰۰ پیک)\*\*** **\*\*≈ (۲۰:۱) CCU به MAU نسبت\*\*** **\*\*MAU (۲۰۰,۰۰۰ MAU)\*\***.

گلوگاه شناخته شده **\*\*| ظرفیت فعلی\*\*** | **\*\* (Resource) منبع\*\*** |  
راهکار **\*\*| Scale-out حد آستانه برای\*\*** | **\*\* (CCU برای ۱۰۰۰)**  
**\*\*مقیاس پذیری\*\*** |

| :--- | :--- | :--- | :--- |

**\*\*CPU\*\*** | **\*\* (Node.js) Game Engine نمونه سرویس\*\*** |  
هر اتاق. | ۱ نمونه = State و **\*\*حافظه\*\*** برای **\*\* (Node.js) تک هسته\*\***  
~۷۰۰ اتصال پایدار. | **\*\*۶۰۰ اتصال\*\*** در هر نمونه. | **\*\*مقیاس افقی\*\***:  
API در **\*\*RoomID\*\*** اضافه کردن نمونه های جدید. **\*\*روتینگ مبتنی بر Gateway.** |

| **\*\*Redis\*\* (State بازی + Pub/Sub)** | **\*\*و\*\*** |  
**\*\*CPU >\*\*** | **\*\*تأخیر\*\*** در صورت فشار بالا. | نسخه فعلی: ۱ نمونه  
**\*\*Redis\*\*** ارتقا به کلاستر ۱. | **\*\*Latency > ۵ms\*\*** یا **\*\*۷۰%\*\***

به RoomID شاردینگ اتاق‌ها\*\* بر اساس \*\*۲. <br>(Redis Cluster).  
| Redis. چندین نمونه

| \*\*PostgreSQL\*\* (تعداد) | Connection داده کاربر/کاراکتر) |  
| همزمان\*\* و \*\*پرفورمنس کوئری‌های گزارش‌گیری.\*\* | ۱ نمونه  
| \*\*ms\*\* یا \*\*کوئری‌های کند < ۲۰۰ %۸۰ Connection Pool > \*\* |  
۲. <br>PgBouncer با \*\* (Connection Pooling) اتصال پول \*\* ۱.  
۳. <br>برای کوئری‌های گزارش \*\* (Read Replica) خواندنی/نوشتنی \*\*  
| Citus) (با شاردینگ \*\* طولی مدت \*\* |

| \*\*Real-time ترافیک\*\* | \*\* (Network Bandwidth) پهنای باند شبکه \*\* |  
مگابیت بر ثانیه. | \*\*استفاده < ۱۰۰ ~ |  
| \*\*۷۰%\*\*. | ارتقای پهن شبکه با ارائه‌دهنده کلاد

| برای \*\* (RAM) مقدار حافظه \*\* | \*\*API Gateway (Kong) \*\* |  
| Load Balancer. کش و تعداد اتصالات همزمان. | ۲ نمونه پشت  
| Kong. مقیاس افقی \*\* نمونه‌های \*\* | \*\*CPU > ۷۵% \*\* |

---

\*\* (Load Testing Plan) برنامه تست بار ۳. \*\* ##

**\*\*هدف: \*\*شناسایی محدودیت‌های سیستم قبل از مواجهه واقعی**

**\*\*ابزارها و محیط ۳,۱. \*\*\***

و JS به دلیل سادگی، اسکریپت‌نویسی با **\*\*k6\*\*** ابزار: **\*\*ابزار \*\*** \*  
(Grafana یکپارچگی با

است (اما Production که دقیقاً مشابه **\*\*Staging\*\*** محیط: **\*\*محیط \*\*** \*  
با نمونه‌های کوچک‌تر)

**\*\*Production (anonimized)\*\*** داده تست: **\*\*از \*\*دیتابیس \*\*** \*  
برای تست واقعی‌تر استفاده می‌شود

**\*\*سناریوهای تست بار ۳,۲. \*\*\***

حفظ پیک **\*\*، \*\* (Ramp-up)** هر تست **\*\*۳ مرحله \*\*** دارد: **\*\*رَمپ آپ**  
**\*\* (Ramp-down) رَمپ داون \*\*، \*\* (Sustain)\*\***

**\*\*سناریو \*\* | \*\*هدف \*\* | \*\*پرو فایل بار \*\* | \*\*معیارهای موفقیت \*\* |**

**--- | --- | --- | --- |**

و CRUD های API ثبت نام و ساخت کاراکتر انبوه\*\* | تست :LT-۱\*\* |  
در ۵ دقیقه. حفظ ۵ دقیقه. | • نرخ خطای VU → ۵۰۰ VU دیتابیس. | ۵۰  
• PostgreSQL  
• P95 Latency < ۳۰۰ ms.  
• HTTP < ۱%.  
CPU < ۸۰%. |

تست سرویس | \*\*Real-time\*\* شبیه سازی کاربران بازی :LT-۲\*\* |  
پیچیده:\*\* ایجاد ۲۰۰ "اتاق بازی" | Redis. و Game Engine  
هر بازیکن هر ۱۰ ثانیه (CCU مجموعاً ۸۰۰) "مجازی، هر کدام ۴" بازیکن  
• WebSocket < ۰,۵%. می فرستد. | • نرخ قطعی Action یک  
• Redis Latency  
Game Action Latency (P99) < ۷۰۰ ms.  
• Game Engine CPU < ۷۰%. نمونه های < ۱۰ ms.

API پیک ترافیک (برگشت از کمپین مارکتینگ)\*\* | تست :LT-۳\*\* |  
در ۲ VU و مقیاس خودکار. | افزایش سریع از ۱۰۰ به ۱۵۰۰ Gateway  
• API Gateway Latency (P95) < ۳ دقیقه. حفظ ۳ دقیقه  
| .سرویس ها ظرف ۳ دقیقه فعال شود • Auto-scaling < ۲۵۰ ms.

memory شناسایی | \*\*Endurance Test\*\* استقامت :LT-۴\*\* |  
در طول زمان. | بار ثابت معادل ۵۰٪ از ظرفیت Degradation یا leak  
پیش بینی شده پیک برای \*\*۲ ساعت\*\*. | • هیچ گونه افزایش تدریجی  
| .بیش از ۲۰٪ Latency یا Memory Utilization



\*\*\*:فرکانس اجرا ۳,۳\*\*###

- \* \*\* (اجباری) \*\* \*
- \* \*\* (برای اطمینان از حفظ عملکرد) \*\* \*
- \* \*\* (اجباری) \*\* \*

---

\*\*\* به تفکیک لایه (Scalability Plan) برنامه مقیاس پذیری ۴\*\*##

\*\*\* (Application Scaling) مقیاس پذیری برنامه ۴,۱\*\*###

- \* \*\* Auto-scaling (Gatewayها، Stateless - API) استاتلس \*\* \*
- scaling CPU/Memory Utilization افقی \*\* بر اساس
- \* \*\* به مدت ۱  $\text{CPU} > 70\%$  اگر `scale up` \*\* K8s HPA: قانون \*\* \*
- به مدت ۵ دقیقه  $\text{CPU} < 30\%$  اگر `scale down`. دقیقه
- \* \*\* Auto-scaling (Stateful - Game Engine): استیت فول \*\* \*
- افقی با هوشمندی
- \* \*\* اتاق های خاصی را در حافظه دارد State چالش: هر نمونه، \*\* \*

راهکار: \*\* استفاده از \*\* شاخص \*

زمانی که میانگین اتصالات هر نمونه از ``connections_per_pod`` ۶۰۰ گذر کند، نمونه جدید ایجاد می‌شود. \*\* اتاق‌های جدید \*\* به نمونه‌های State شود، اتاق‌هایش بر اساس Fail کم‌بارتر هدایت می‌شوند. اگر نمونه‌ای ، به نمونه‌های دیگر مهاجرت می‌کنند Redis ذخیره‌شده در

\*\*\* (Data Scaling) مقیاس‌پذیری داده ۴,۲۰۰ \*\* ###

مسیر تکامل: \*\* PostgreSQL: \*

۱. Connection Pooling با PgBouncer (هم‌اکنون) \*\*
۲. برای \*\* Read Replica \*\* افزودن (MAU > ۵۰,۰۰۰ در) \*\*  
کوئری‌های گزارش و تحلیل
۳. بر (Sharding) شاردینگ (MAU > ۵۰۰,۰۰۰ در) \*\*  
\*\* Citus \*\* با استفاده از ``user_id`` اساس

مسیر تکامل: \*\* Redis: \*

۱. (هم‌اکنون) \*\* (یک نمونه قوی) \*\*
۲. برای \*\* Redis Cluster \*\* راه‌اندازی (CCU > ۵,۰۰۰ در) \*\*  
توزیع داده و بار

\* \*\*ClickHouse:\*\* به طور ذاتی برای بارهای تحلیلی سنگین مقیاس پذیر افقی است.

\*\*\* \*\*CDN\*\* مقیاس پذیری شبکه و ۴,۳۰

\* \*\*CDN:\*\* های asset برای ارائه \*\*Cloudflare\*\* استفاده از (JS، CSS، تصاویر،) استاتیک می شود.

\* \*\*بند:\*\* ارتقای پلن شبکه با ارائه دهنده کلاد

---

## \*\* (Cost Projection) برآورد هزینه رشد ۵.

ما هزینه ها را بر اساس \*\*مدل مصرف منابع در پلتفرم کلاد داخلی\*\* (مثلاً دیجی کالا کلاد) برآورد می کنیم

سناریو کاربری | \*\*منابع مورد نیاز\*\* | \*\*هزینه ماهانه\*\* |  
| \*\*تخمینی\*\* | \*\*توضیح

| :--- | :--- | :--- | :--- |

نمونه ۴ • | K (پیک: ۱) MAU: ۲۰K, CCU  
پایه (سال اول) \*\* |  
هسته، ۲) سایر API/ نمونه ۲ • Game Engine (۲ GB هسته، ۲)  
• PostgreSQL (۴GB RAM) • Redis  
۲GB) • ۲۰۰ GB پهنای باند: ۲۰۰ (۲GB)  
MVP | \*\* میلیون تومان ۸-۱۲ ~ \*\* |  
در حال رشد |

K (پیک: ۱۰) MAU: ۲۰۰K, CCU  
مقیاس متوسط (سال دوم) \*\* |  
• Game Engine نمونه ۱۵ •  
• سایر API/ نمونه ۶ •  
PostgreSQL + Read Replica (۸GB) • Redis Cluster (۳  
Node) • ۲ TB پهنای باند: ۲ •  
میلیون تومان \*\* | مرحله ۴۰-۶۰ ~ \*\* |  
رشد سریع |

MAU: ۱M, CCU  
مقیاس بزرگ (سال سوم/بین المللی) \*\* |  
نمونه ۲۰ • Game Engine نمونه ۷۵ • | K (پیک: ۵۰)  
• PostgreSQL Sharded (Citus) • Redis  
API/ سایر  
میلیون ۲۰۰-۳۵۰ ~ \*\* | TB+ پهنای باند: ۱۰ •  
Cluster بزرگ  
| تومان \*\* + هزینه کلاد بین المللی برای دیاسپورا. | پلتفرم پایدار و سودآور

نکته: \*\* این هزینه ها فقط زیرساخت \*\* است. هزینه های نیروی  
انسانی، مارکتینگ و سایر عملیات جداگانه است.

---

**\*\*جمع‌بندی: آیا سیستم از پا درمی‌آید؟ ۶. \*\*##**

بر اساس این برنامه، پاسخ **\*\*خیر\*\*** است — اگر و تنها اگر

۱. مانیتورینگ فعال **\*\*** ما هشدارها را به موقع شناسایی کند **\*\***

تست‌های بار منظم **\*\*** گلوگاه‌های جدید را قبل از بروز مشکل آشکار **\*\*** ۲. کند.

۳. به درستی پیکربندی شده باشند **\*\*Auto-scaling Rules\*\***

۴. **转折 (Inflection Point)** ظرفیت مالی **\*\*** برای ارتقای منابع در نقطه **\*\*** وجود داشته باشد.

**\*\*بزرگ‌ترین ریسک‌های مقیاس‌پذیری\*\***

**Real-time** بازی **State** مشکل اصلی ما **\*\*مدیریت Stateful: گلوگاه\*\*** \*  
**Redis** در مقیاس ده‌ها هزار کاربر همزمان **\*\*** است. راهکار شاردرینگ **time**  
بر این چالش متمرکز است **Game Engine** و معماری

می‌تواند هزینه زیرساخت را به طور خطی CCU هزینه: \*\* رشد نمایی \*\* \*  
باید به گونه‌ای باشد که (Freemium) افزایش دهد. \*\* مدل درآمدی ما  
\*\* کاربر پولی، هزینه زیرساخت کاربران رایگان را پوشش دهد LTV

این سند نقشه راهی است که تضمین می‌کند \*\* مهندسی همگام با رشد  
کسب و کار حرکت می‌کند \*\*. ما نه تنها می‌دانیم سیستم امروز چگونه کار  
می‌کند، بلکه می‌دانیم فردا با دوبرابر شدن کاربران، چه اقداماتی باید انجام  
دهیم و این اقدامات چقدر هزینه خواهد داشت. این \*\* قابلیت پیش‌بینی \*\*،  
کلید رشد کنترل‌شده و بدون شوک است.